



中山大学计算机学院

信号与系统

综合实验报告

(2022学年春季学期)

小组成员	分工
李昊伟	实验设计与实现、报告撰写
李君豪	文献调研
唐梓杰	文献调研
谭夷翔	文献调研

1. 实验题目

实验三: 滤波器设计在图像处理中的应用

2. 实验的相关知识准备

1. 二维傅里叶变换

通俗来讲, 一维傅里叶变换是将一个一维的信号分解成若干个三角波。这个信号说白了就是一个时域上的函数, 不管是离散的还是连续的。

在上学期的《数学分析III》中我们已经学过, 函数可以推广到多元。那么, 一个具有二元变量的离散信号, 比如图像, 也会有它对应的二维傅里叶变换。

参照《数字图像处理》第四章的内容, 我们可以推广得到二维图像的傅里叶变换对以及它的性质。由于篇幅原因, 这里只贴出二维图像傅里叶变换对的公式。

DFT(傅里叶变换):

$$\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \times e^{-j2\pi(ux/M+vy/N)}$$

IDFT(傅里叶反变换):

$$f(x, y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v) \times e^{j2\pi(ux/M+vy/N)}$$

在二维离散情况下, 我们用 (x, y) 表示空间变量, (u, v) 表示时间变量。

对于一个 $M * N$ 的图像, 可以看作 M 行 N 列的二维数组, 先对每行做一维FFT, 将结果作为一个新的二维数组。再对新的二维数组每列做一维FFT。而在处理二维IFFT的时候, 跟二维FFT差不多, 只要在公共方法中控制正负值, 来区分是FFT还是IFFT。

在opencv中和numpy中, 都实现了对图像的二维傅里叶变换和反变换, 在本实验中将直接使用。


以下是Lena图在空间域与时间域上的形式:



2. 巴特沃斯滤波器

巴特沃斯 (Butterworth) 滤波器是一种具有最大平坦幅度响应的低通滤波器。

说起低通滤波器，我们第一个想到的是理想低通滤波器。也就是把限定低频范围内所有信号成分保留，然后把不在限定范围内的所有信号成分滤去。



这样的滤波器，如课堂习题

多选题 2分

- 由于理想滤波器在时域表现上“不理想”，设计实际滤波器时常需要对频域与时域特性进行折中。

为何理想滤波器在时域表现上“不理想”？

- ☐ A 不稳定
- ☐ B 非因果
- ☐ C 存在振铃效应
- ☐ D 不可逆



会引起振铃效应。在实验当中我们将分析振铃效应的成因，并发现如果使用巴特沃斯滤波器会有效地消除振铃效应。截止频率位于距离原点 D_0 处的 n 阶巴特沃斯低通滤波器的传递函数定义为：

$$H(u, v) = \frac{1}{1 + [D(u, v)/D_0]^{2n}}$$

直观上来讲，该滤波器会使非截止频率范围内的信号成分通过。如图：



在实验中，我将分析振铃现象的成因以及实现没有振铃现象的巴特沃斯滤波器。

3. 退化函数

对于一个图像的运动模糊过程，在空间域上似乎是比较复杂的。我们很想用频域上的一些加加减减乘乘除除来表示它，这是可以做到的吗？首先，我们要知道一个图像的退化过程是怎样用一个函数来表示的，这就是退化函数。

我们首先了解一些概念。

如果我们把 $f(\mathbf{x}, \mathbf{y})$ 视为空间域上的图像信号的话，那么我们可以把退化过程描述为：

$$g(x, y) = H[f(x, y)] + \eta(x, y) \quad (1)$$

其中 H 表示作用在图像上的退化， η 表示加性噪声，就是一个与位置无关，直接加在空间域图像上的噪声项。

- 线性：

$$H[af_1(x, y) + bf_2(x, y)] = aH[f_1(x, y)] + bH[f_2(x, y)] \quad (2)$$

- 位置不变性(类时不变性)：

$$H[f(x - \alpha, y - \beta)] = g(x - \alpha, y - \beta) \quad (3)$$

也就是说图像中任意一点的响应只取决于其输入，而与位置本身无关。

- 点扩散函数(PSF)

我们推广一维的取样函数到二维，得到：

$$f(x, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(\alpha, \beta) \times \delta(x - \alpha, y - \beta) d\alpha d\beta$$

代入(1), 假设 H 是线性系统，得到：

$$g(x, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(\alpha, \beta) \times h(\delta(x - \alpha, y - \beta)) d\alpha d\beta$$

已经很明了了，这里的 $h(\mathbf{x}, \alpha, \beta, \mathbf{y}) = h(\delta(\mathbf{x} - \alpha, \mathbf{y} - \beta))$ 对应着一维里面的单位冲激响应，图像里的一个冲击为一个光电，响应会是一个模糊化了的光点，所以将冲激响应称为点扩散函数。

同样类比一维，由于复指数信号是线性位置不变系统的特征函数，单位冲激响应的傅里叶变换是特征值，不用推导也能想象到以下结论：

$$g(x, y) = h(x, y) * f(x, y) + \eta(x, y)$$

$$G(u, v) = H(u, v) \times F(u, v) + N(u, v)$$

事实上，任何一个线性空间不变退化系统，如果它具有加性噪声，那它退化后的频域图 $G(u, v)$ 可以被表示为：

$$G(u, v) = H(u, v) \times F(u, v) + N(u, v)$$

4. 逆滤波和维纳滤波

已知有

$$G(u, v) = H(u, v) \times F(u, v) + N(u, v)$$

可以推出 $F(u, v)$ 的估计:

$$\hat{F}(u, v) = F(u, v) + \frac{N(u, v)}{H(u, v)}$$

这就是逆滤波，直接忽略噪声，把 H 除掉就好。可是如果 $H(u, v)$ 为0或者很小的值， $\frac{N(u, v)}{H(u, v)}$ 会很容易支配估计值，使得恢复的图像成为一团混乱。

于是引入维纳滤波。

维纳滤波也称最小均方差滤波，它能处理被退化函数退化和噪声污染的图像。该滤波方法建立在图像和噪声都是随机变量的基础之上，目标是找到未污染图像 $f(x, y)$ 的一个估计，使它们之间的均方误差最小。

这种误差度量用以下式子表示：

$$e^2 = E[(f - \hat{f})^2]$$

其中， E 是参数的期望值。其数学推导比较复杂，篇幅原因这里不作展开，直接给出估计值的表达式：

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \times \frac{|H(u, v)|^2}{|H(u, v)|^2 + K} \right] \times G(u, v)$$

3. 实验内容

1. 实验任务1：

对数字图像进行不同参数下的理想滤波（低通、高通、带通），并分析得到的结果

• 解决问题的方法分析


1. 将图像经过二维傅里叶变换，变换到频域上去，并且通过移动，使得频率图显现中间低频，外围高频的格局。
2. 设计相应的滤波器掩膜。
3. 将相应的掩膜与频域图像相乘，再将图像变换回去。

• 实验过程与关键代码：

1. 将图像经过二维傅里叶变换，变换到频域上去，并且通过移动，使得频率图显现中间低频，外围高频的格局。

```
def dft(img):  
    img_float32 = np.float32(img)  
    dft = cv2.dft(img_float32, flags=cv2.DFT_COMPLEX_OUTPUT)  
    dft_shift = np.fft.fftshift(dft)  
    return dft, dft_shift
```

2. 设计相应的滤波器掩膜。



```
def high_pass_filter(shape, radius):  
    h, w = shape  
    mask = np.ones((shape[0], shape[1], 2), dtype=np.uint8)
```

```

cv2.circle(mask, (int(w / 2), int(h / 2)), radius, (0, 0, 0), -1)
filter_for_show = np.full(shape[:2], 255, dtype=np.uint8)
cv2.circle(filter_for_show, (int(w / 2), int(h / 2)), radius, (0, 0, 0), -1)
return mask, filter_for_show

def high_pass_filtering(filter_range, shape, spectrum):
    # 理想高通滤波器: 将中心半径30内的谐波全部滤掉(置为0)
    mask, high_pass_filter_for_show = high_pass_filter(shape, filter_range)
    filtered_spectrum = mask * spectrum
    # 将频谱从中心低频的状态移动回原来的状态
    shifted_back = np.fft.ifftshift(filtered_spectrum)
    # 傅里叶反变换
    img_back = cv2.idft(shifted_back)
    # 计算幅度值
    img_back = cv2.magnitude(img_back[:, :, 0], img_back[:, :, 1])
    # 由于快速傅里叶变换的性质, 这里除上采样个数
    img_back = np.uint8(img_back / (shape[0] * shape[1]))

    show_high_pass = get_spectrum_as_picture(filtered_spectrum)
    cv2.imwrite("./result/high_pass/high_pass_filtered_spectrum1.jpg", show_high_pass)
    cv2.imwrite("./result/high_pass/high_pass_filter.jpg", high_pass_filter_for_show)
    return img_back, mask
### 低通, 带通同理, 见源码

```


3. 将相应的掩膜与频域图像相乘, 再将图像变换回去

• 结果分析:

1. 输出的图片(分别是高通、低通、带通):



2. 输出的图片的频谱(分别是高通、低通、带通):



3. 振铃现象:



可以看到理想低通滤波器产生的图片表面很不光滑，有很多如同振铃使得空气振动产生的气泡状。究其原因，是由于像素值快速变化造成的。

由于理想低通滤波器在频率域中、把其中一维视为定值，将二维函数看成是个一维函数。发现它是一个方波信号。那么，在空间域，其信号具有sinc函数形状。将图像的每一个像素视为一个离散冲激，它的强度和灰度成正比。我们熟悉，频率域相乘，空间域卷积。那么就相当于在冲击的地方复制这个sinc函数。事实上，二维理想低通滤波器的mask在频域上类似一个小山包，相当于四处搬运这个sinc小山包。sinc的中心波瓣是引起模糊的主因，而外侧较小的波瓣是造成振铃的主要原因。

实验任务2.

设计适当的非理想滤波器（如巴特沃斯滤波器）对相同的图像进行滤波，并与理想滤波结果进行对比分析；

- 解决问题的方法分析：

前文当中已经提到过巴特沃斯滤波器的表达式，只需要根据表达式生成巴特沃斯滤波器的mask，其他的和任务一完全一样。

- 实验过程与关键代码：

```
def butterworth_lp_filter(shape, rank, radius):
    # 中心位置
    h, w = shape[:2]
    cx, cy = int(w / 2), int(h / 2)
    # 计算以中心为原点坐标分量
    u = np.array([[x - cx for x in range(w)] for i in range(h)], dtype=np.float32)
    v = np.array([[y - cy for y in range(h)] for i in range(w)], dtype=np.float32).T
    # 每个点到中心的距离
    dis = np.sqrt(u * u + v * v)
    mask = 1 / (1 + np.power(dis / radius, 2 * rank))
    filter_for_show = mask * np.full((shape), 255, dtype=np.uint8)
    mask = mask.reshape(shape[0], shape[1], 1).repeat(2,axis=2)
    return mask, filter_for_show

def butterworth_hp_filter(shape, rank, radius):
    # 中心位置
    h, w = shape[:2]
    cx, cy = int(w / 2), int(h / 2)
    # 计算以中心为原点坐标分量
    u = np.array([[x - cx for x in range(w)] for i in range(h)], dtype=np.float32)
    v = np.array([[y - cy for y in range(h)] for i in range(w)], dtype=np.float32).T
    # 每个点到中心的距离
    dis = np.sqrt(u * u + v * v)
    # 高通滤波
    mask = 1 - 1 / (1 + np.power(dis / radius, 2 * rank))
    filter_for_show = mask * np.full((shape), 255, dtype=np.uint8)
    mask = mask.reshape(shape[0], shape[1], 1).repeat(2,axis=2)
    return mask, filter_for_show

def butterworth_filtering(rank, filter_range, shape, spectrum, mode):
    if mode == 'low_pass':
        mask, butterworth_filter_for_show = butterworth_lp_filter(shape, rank, filter_range)
    else:
        mask, butterworth_filter_for_show = butterworth_hp_filter(shape, rank, filter_range)
    filtered_spectrum = mask * spectrum
    # 将频谱从中心低频的状态移动回原来的状态
```

```


shifted_back = np.fft.ifftshift(filtered_spectrum)
# 傅里叶反变换
img_back = cv2.idft(shifted_back)
# 计算幅度值
img_back = cv2.magnitude(img_back[:, :, 0], img_back[:, :, 1])
# 微调, 见实验报告本处注释
img_back = np.uint8(img_back / (shape[0] * shape[1]))

show_low_pass = get_spectrum_as_picture(filtered_spectrum)
if mode == "low_pass":
    cv2.imwrite("./result/butterworth/butterworth_filtered_spectrum1.jpg", show_low_pass)
    cv2.imwrite("./result/butterworth/butterworth_filter.jpg", butterworth_filter_for_show)
else:
    cv2.imwrite("./result/butterworth/butterworth_hp_filtered_spectrum1.jpg", show_low_pass)
    cv2.imwrite("./result/butterworth/butterworth_hp_filter.jpg",
butterworth_filter_for_show)
    return img_back, mask

```

- 结果分析:

巴特沃斯滤波器模板示意图:



巴特沃斯滤波与理想滤波对比:



巴特沃斯低通滤波器的阶数越高，其在空间域上的“震荡”就越弱，如同冈萨雷斯的《数字图像处理 第三版》图4.46所示那样。（我在网络上似乎难以找到此图），导致产生的振铃现象越弱。

实验任务3

假设图像拍摄时存在运动模糊，之后还叠加了一定程度的高斯随机噪声，试通过编程对这一图像质量退化过程进行仿真。

- 运动模糊的退化函数推导：从运动模糊的成因开始(建模估计法)

假设图像曝光的时间为 T ，在这段时间里图像运动的水平、垂直距离分别是 $x_0(t)$ 和 $y_0(t)$ 。

根据照片成像原理, $g(x, y) = \int_0^T f[x - x_0(t), y - y_0(t)] dt$

直接对其进行傅里叶变换：

$$G(u, v) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) \times e^{-j2\pi(ux+vy)} dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \left[\int_0^T f[x - x_0(t), y - y_0(t)] dt \right] \times e^{-j2\pi(ux+vy)} dx dy$$

改变积分次序：

$$G(u, v) = \int_0^T \left[\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f[x - x_0(t), y - y_0(t)] \times e^{-j2\pi(ux+vy)} dx dy \right] dt$$

发现方括号内正好是 $f(x - x_0(t), y - y_0(t))$ 的傅里叶变换。

$$G(u, v) = F(u, v) \times \int_0^T e^{-j2\pi[ux_0(t)+vy_0(t)]} dt$$

也就是我们熟悉的：

$$G(u, v) = H(u, v)F(u, v)$$

$$H(u, v) = \frac{T}{\pi(ua+vb)} \times \sin[\pi(ua + vb)] \times e^{-j\pi(ua+vb)}$$

- 运动模糊的退化函数推导，从PSF开始

$$h(x, y) = \frac{1}{L} \quad 0 \leq x \leq L, y = 0 \quad (4)$$

对式(4)中的点扩散函数做傅立叶变换：

$$\begin{aligned} H(u, v) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} h(x, y) e^{-j2\pi(ux+vy)} dx dy \\ &= \int_0^L \frac{1}{L} e^{-j2\pi ux} dx \\ &= \frac{\sin(\pi uL)}{\pi uL} e^{-j\pi uL} \end{aligned} \quad (5)$$

可以发现，这里的 $L = 1/a$

- 实验过程与关键代码

- 生成运动模糊退化函数H

```
def degradation_function(pic , a=0, b=0 , T=1):
    [r,c] = pic.shape
    u = np.arange(r).reshape((-1,1)) - np.ceil(r/2)
    v = np.arange(c)-np.ceil(c/2)
    tmp = np.pi*(u*a + v*b)      #广播机制得到矩阵
    tmp[tmp==0]=1e-20
    H = T*np.sin(tmp)/tmp*np.exp(-1j*tmp);  # 退化函数
    return H
```

- 进行运动模糊,添加高斯噪声


```
def motion_blur_v2(pic , H):
    g = np.fft.ifft2(H * np.fft.fft2(pic));
    g = np.uint8(np.real(g))
    return g
```


```
def add_gauss_noise(img, sigma):
    img = img/255
    noise = np.random.normal(0,sigma,img.shape)
    output = img + noise
    output = np.clip(output, 0, 1)
    output = np.uint8(output * 255)
    return output
```

- 实验结果分析


- 添加运动模糊前的图像及其频谱



- 添加运动模糊后的图像及其频谱



- 添加高斯噪声后的运动模糊图像及其频谱



实验任务4

如果已知上述图像退化过程的参数，请编程实现对已退化图像的复原。

- 实验过程与关键代码
 - 尝试直接逆滤波

```
def inverse_filtering(input, H, eps):  
    input_fft = np.fft.fft2(input)  
    PSF_fft = H + eps # 避免除数为0添加的一个极小量，可以防备一定的噪声  
    result = np.fft.ifft2(input_fft / PSF_fft)  
    result = np.abs(result)  
    return result
```


- 维纳滤波

```
def wiener_filtering(input_signal, H, K, eps):  
    input_signal_cp = np.copy(input_signal) # 输入信号的副本  
    input_signal_cp_fft = np.fft.fft2(input_signal_cp) # 输入信号的傅里叶变换  
    PSF_fft = H + eps  
    h_abs_square = np.abs(PSF_fft)**2 # 退化函数模值的平方  
    # 维纳滤波  
    output_signal_fft = np.conj(PSF_fft) / (h_abs_square + K)  
    output_signal = np.abs(np.fft.ifft2(output_signal_fft * input_signal_cp_fft)) # 输出信号傅里叶反变换  
    return output_signal
```

- 实验结果分析
 - 直接逆滤波作用在无噪声的运动模糊图像上



- 直接逆滤波作用在有噪声的运动模糊图像上




- 维纳滤波作用在有噪声的运动模糊图像上



实验思考

如果退化过程的参数未知，如何进行复原？请编程实现，并与参数已知时的结果进行比较。

- 由于PSF是 $H(u, v) = \frac{T}{\pi(ua+vb)} \times \sin[\pi(ua+vb)] \times e^{-j\pi(ua+vb)}$ ，是一个sinc函数，是一个显然有零点的函数，所以我们在运动模糊后的图像频谱上，看到许多暗线。在高斯噪声添加后，暗线变得不那么明显，我们可以用高斯卷积核 (gaussian blur) 减缓这种影响，如下图(无高斯噪声-> 有高斯噪声->高斯模糊)：



- 理论推导：L与暗条纹距离之间的距离


论。设图像有 N 行, 对式(5)进行离散化, 得到表达式:

$$H(u) = \frac{\sin(\pi u L / N)}{\pi u L / N} \quad (6)$$

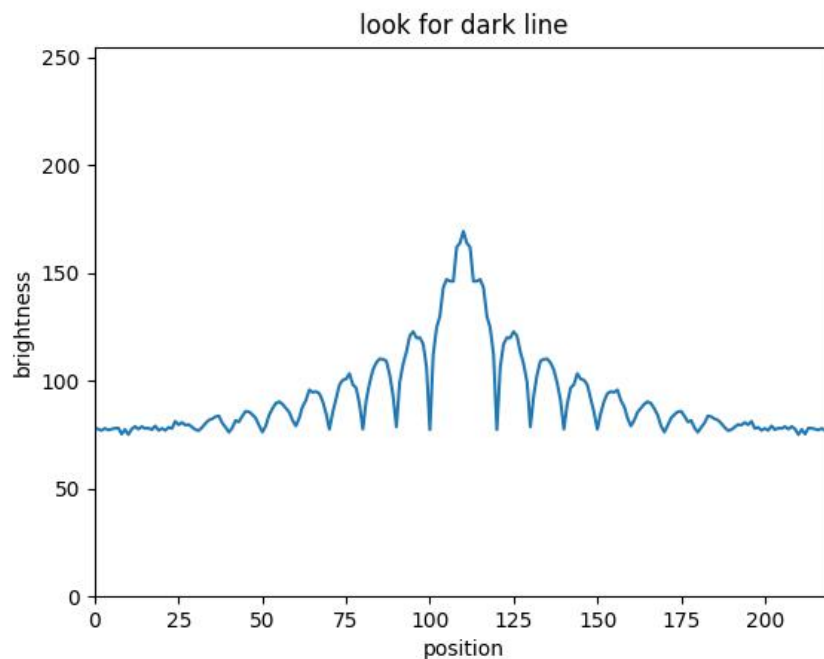
令 $H(u) = 0$, 则 $\sin(\pi u L / N) = 0$, 假设有 2 个频谱图上连续的零点 u_1, u_2 , 则满足 $\frac{\pi u_2 L}{N} - \frac{\pi u_1 L}{N} = \pi$, 化简可得到 $u_2 - u_1 = \frac{N}{L}$, 而 $(u_2 - u_1)$ 就是运动模糊图像频谱图中暗条纹之间的距离, 设为 D , 则得到式(7)。

$$L = \frac{N}{D} \quad (7)$$

- 画出频谱列平均像素，观察其明暗变化，找到暗线所在的位置，根据低谷之间的距离确定D:



- 和没有添加高斯噪声的只有运动模糊的平均像素图对比，发现确立了同一个L:



- $N = 216$, $D = 20$, $L = 10.8$, 基本正确。
- 寻找暗线的代码

```
def show_line_in_plt(shape , spectrum , filename):
    size = spectrum.shape[0]
    sample = [ it.sum()/it.shape[0] for it in spectrum.T]
    fig = plt.figure()
    ax = fig.add_subplot(111)
    ax.set(xlim=[0, shape[1]], ylim=[0, 255], title='look for dark line',
           ylabel='brightness', xlabel='position')
    x = np.arange(0, shape[1])
    y = sample
    ax.plot(x, y)
    plt.savefig(filename)
    plt.show()
```

实验感想

在本次实验中，遇到了不少问题，也查阅了不少资料，感觉很充实。特别关注了一些数学推导，动笔计算后感觉对一维的信号傅里叶变换对理解更透彻了。

本来就对数字图像处理感兴趣，现在确实体会到了信号与系统在图像处理方面的运用。虽然完成了实验，但是我们还会多方继续调研，了解运动模糊的相关信息，找到更好的deblur方法。我们也深深体会到，噪声就像图像的癌症，一个本来并不复杂的问题，加上噪声就会复杂起来，甚至完全无法下手。

参考资料

《数字图像处理》第三版 冈萨雷斯

《运动模糊图像PSF参数估计与图像复原研究》 廖秋香 卢在盛 彭金虎

https://blog.csdn.net/qq_42240908/article/details/112745898